

PROJET 7 · INGÉNIEUR IA

Réalisez une analyse de sentiments grâce au Deep Learning

Concevoir, comparer et mettre en production un modèle capable de prédire le sentiment d'un tweet, pour permettre à la compagnie aérienne Air Paradis d'anticiper les bad buzz.

Dimitri Wyts

MIC · Marketing Intelligence Consulting

Sommaire

I

Contexte et préparation

Le besoin d'Air Paradis, le jeu de données, le nettoyage et ce que l'exploration a révélé.

II

Les trois approches

Modèle classique, modèle sur mesure avancé, BERT. Ce qu'elles font, pourquoi ces choix, et leurs résultats.

III

La comparaison

Pourquoi la lecture naïve des scores est trompeuse, et ce que donne une comparaison honnête.

IV

La démarche MLOps

Suivi des expérimentations, centralisation des modèles, versioning, tests automatisés, déploiement continu.

V

La mise en production

L'API sur le cloud, ce qui casse entre le notebook et la production, le suivi de la performance et les alertes.

VI

Bilan et perspectives

La réponse au client et la démarche d'amélioration du modèle dans le temps.

Comment j'ai travaillé avec l'IA, et comment je l'ai contrôlée

Je préfère le dire en ouverture plutôt qu'en réponse à une question. Je me suis aidé d'un assistant IA tout au long de ce projet. Ce qui m'intéresse ici n'est pas de l'avoir utilisé, c'est **la façon dont je l'ai contrôlé**, parce que c'est là que se joue la différence.

1

Ce pour quoi je m'en suis servi

Écrire du code répétitif, expliquer un message d'erreur, proposer des pistes quand je bloquais, et relire mon travail de façon critique.

2

Ma règle, tenue du début à la fin

Aucun chiffre de ce support ne vient d'une suggestion. Chacun sort d'une exécution que je peux rouvrir, dans un notebook ou dans MLflow. Quand une explication était plausible mais non mesurée, je l'ai mesurée.

3

Ce que ça m'a appris

Un assistant propose des causes vraisemblables, et une cause vraisemblable n'est pas une cause. Le travail d'ingénieur commence là : décider quoi mesurer pour trancher.

Quatre fois où elle s'est trompée, et comment je l'ai su

Une sauvegarde bloquée 46 minutes attribuée au mauvais composant. La vraie cause, trouvée en inspectant la pile d'exécution, était la bibliothèque de sérialisation.

Un entraînement passé de 65 à 941 secondes, expliqué deux fois de suite par une mauvaise raison. La vraie cause était la mémoire saturée qui écrivait sur le disque.

Une bibliothèque déclarée indisponible pour ma version de Python. Une requête directe au dépôt de paquets a montré le contraire.

Un réglage d'alerte conseillé à tort, qui m'a valu cinq courriels pour un seul incident.

Et une fois où elle a trouvé ce que j'avais raté

En lui demandant une relecture critique de mes propres résultats, elle a montré que ma conclusion principale, un écart de 0,57 point, **n'était pas démontrée** : mesurée sur 4 000 tweets, elle était plus petite que ma marge d'erreur.

J'ai refait la mesure sur 251 730 tweets. La conclusion tient, et l'écart est même plus large. C'est la diapositive 23.

Contexte et objectifs du projet

« Air Paradis veut un prototype d'un produit IA permettant de prédire le sentiment associé à un tweet. »

Le besoin métier

Air Paradis n'a pas toujours bonne presse sur les réseaux sociaux.

Un message négatif repéré dans l'heure se traite. Le même repéré trois jours plus tard est devenu une crise.

La contrainte

Aucune donnée client exploitable chez Air Paradis.

Il faut donc partir de **données open source**, et accepter les limites de ce qu'elles contiennent.

La demande élargie

Marc, mon manager, veut « faire d'une pierre deux coups » : un prototype pour le client, et une **démarche MLOps** exemplaire diffusable aux autres équipes.

Ce qui est demandé

Trois approches comparées, de la régression logistique aux modèles de langue pré-entraînés. Le modèle avancé exposé par une API déployée sur le cloud, appelée depuis une interface locale.

Pourquoi c'est important pour Air Paradis

Le coût des deux erreurs n'est pas symétrique. Rater un tweet négatif, c'est une crise qui démarre sans qu'on la voie. Signaler à tort un tweet positif, c'est trente secondes perdues pour un chargé de communication.

Début du projet : environnement et contraintes

L'environnement de travail

Python 3.13 dans un **environnement virtuel isolé**, pour que la liste des packages livrée ne contienne que ce dont le projet a besoin.

VS Code pour les notebooks et le code, Git dès le premier jour.

La contrainte matérielle

Un ordinateur portable, **16 Go de mémoire**, **aucune carte graphique dédiée**.

Cette contrainte a dicté presque toutes les décisions techniques du projet, et je la documente à chaque fois.

La méthode adoptée

Mesurer avant de décider. Chaque choix d'architecture ou de réglage a été précédé d'un chronométrage sur un échantillon réduit.

Cela m'a évité de lancer des entraînements de plusieurs heures pour rien, et plusieurs fois de me tromper.

Le découpage du dépôt

Deux mondes séparés : `src/` pour la recherche, qui peut dépendre de TensorFlow, et `api/` pour la production, qui doit tenir dans 1 Go.

Un seul fichier traverse la frontière, et c'est le sujet de la diapositive 8.

Le jeu de données : Sentiment140

1,6 M 50 / 50

tweets en anglais

positifs et négatifs

Ce qu'il contient

Des tweets collectés en 2009, avec leur texte, leur auteur, leur date, et une étiquette binaire.

Je n'utilise que **le texte et l'étiquette** : l'API ne recevra qu'un texte, entraîner le modèle sur des informations qu'il n'aura pas en production n'aurait aucun sens.

Une conséquence qu'il faut dire tout de suite : ces tweets sont en anglais, donc le prototype ne sait traiter que l'anglais. Air Paradis est française. J'y reviens en conclusion, avec ce que coûterait le français.

La limite à connaître, et à assumer

L'étiquetage a été fait **automatiquement** : un tweet contenant une émoticône souriante a été classé positif, un tweet avec une émoticône triste, négatif. Les émoticônes ont ensuite été retirées du texte pour que le modèle ne puisse pas tricher.

C'est ingénieux, mais imparfait : **un tweet ironique accompagné d'un smiley se retrouve étiqueté positif à tort.**

Conséquence directe : il existe un plafond de performance qu'aucun modèle ne pourra franchir, situé autour de 85 % selon la littérature. Il faut le dire au client plutôt que de lui promettre 99 %.

Les bibliothèques Python utilisées, et pourquoi

1 Manipulation des données

pandas et **numpy** pour charger, filtrer et transformer les 1,6 million de tweets. **pyarrow** pour le format Parquet, cinq fois plus compact qu'un CSV et bien plus rapide à relire.

2 Modèle classique

scikit-learn fournit TF-IDF, la régression logistique, le découpage entraînement/test et toutes les métriques. C'est la bibliothèque de référence de l'apprentissage automatique classique.

3 Modèle avancé

TensorFlow et sa surcouche Keras pour le réseau de neurones. **gensim** pour entraîner les vecteurs de mots et télécharger ceux de GloVe.

4 BERT

PyTorch en version processeur uniquement, et **transformers** qui donne accès aux modèles pré-entraînés. La version GPU de PyTorch pèse 2,5 Go pour rien sur cette machine.

5 MLOps

MLflow pour le suivi des expérimentations et le catalogue de modèles. **pytest** pour les tests automatisés. **FastAPI** et **uvicorn** pour l'API.

6 Production et suivi

ai-edge-litert exécute le modèle allégé sur le serveur, à la place de TensorFlow. **streamlit** pour l'interface de test, **azure-monitor-opentelemetry** pour les traces.

Le nettoyage des tweets : la décision qui compte

Ce que fait le nettoyage

Suppression des liens et des mentions, qui n'apportent rien au sentiment mais gonflent le vocabulaire puisque chacun est unique. Décodage des caractères du web, réduction des lettres répétées, retrait de la ponctuation.

Le piège des « mots vides »

Les outils proposent une liste de mots trop courants à supprimer. Le problème est que **ces listes toutes faites contiennent les négations**.

Ce qui se passe si on les applique

« this flight was **not** good »

↓ **retrait des mots vides standard**

« flight good »

Le sens est exactement inversé. Le modèle apprend le contraire de ce qu'il faut.

Ce que j'ai fait

Une liste expurgée de toute négation, de tout intensificateur et de tout contrastif. Et **un test automatique qui échoue** si quelqu'un y réintroduit un jour un de ces mots.

Ce module de nettoyage est écrit **sans aucune dépendance externe**, uniquement avec la bibliothèque standard de Python. C'est ce qui permettra de le faire tourner tel quel sur le serveur de production, qui ne dispose que d'un gigaoctet de mémoire.

Ce que l'exploration a révélé

32

mots de longueur maximale retenue

Mesuré sur le texte nettoyé, pas sur le texte brut. Ce seuil couvre **99,98 %** des tweets et économise 20 % de temps de calcul par rapport à 40.

4,9 %

de doublons après nettoyage

Messages banals, et surtout du spam de robots republié **jusqu'à 1 484 fois**. Le nettoyage les rend identiques en retirant les pseudos qui les différenciaient.

13,5x

écart de fréquence du mot « sad »

Entre tweets négatifs et positifs. Le vocabulaire des deux classes est nettement différencié : **le signal existe** dans les mots pris isolément.

Pourquoi retirer les doublons change tout

Le découpage entre données d'entraînement et données de test se fait au hasard. Si un même texte apparaît 500 fois, il se retrouve **mécaniquement des deux côtés**. Le modèle l'a donc déjà vu pendant l'entraînement : au moment du test, il le reconnaît au lieu de le comprendre.

On appelle cela une **fuite de données**. Le score mesuré devient optimiste, et le modèle paraît meilleur qu'il ne le sera en production, où il ne rencontrera que des tweets inédits. Sans cette correction, tous les chiffres de cette présentation seraient flatteurs et faux.

Les trois approches

De la régression logistique au modèle de langue pré-entraîné. Pour chacune : ce que c'est, à quoi ça sert, pourquoi ce choix, et ce que ça donne.

1

Modèle sur mesure simple

TF-IDF et régression logistique. Le tweet devient un sac de mots pondérés, sans notion d'ordre.

2

Modèle sur mesure avancé

Word embeddings et réseau de neurones récurrent. Le modèle lit enfin la phrase dans l'ordre.

3

Modèle avancé BERT

Un modèle de langue pré-entraîné sur des milliards de mots, qui comprend le contexte de chaque mot.

TF-IDF : qu'est-ce que c'est, à quoi ça sert ?

Le problème à résoudre

Un modèle ne sait manipuler que des nombres. Il faut donc transformer chaque tweet en une liste de nombres.

Le principe de TF-IDF

Term Frequency, Inverse Document Frequency. Un mot est important s'il est **fréquent dans ce tweet-ci, mais rare dans l'ensemble des tweets**.

Le mot *the* apparaît partout, il ne distingue rien, son poids s'effondre. Le mot *terrible* est rare, donc très informatif, son poids monte.

Pourquoi pas un simple comptage ?

Parce qu'un comptage brut donnerait le plus de poids aux mots les plus fréquents, c'est-à-dire à ceux qui n'apprennent rien. TF-IDF corrige exactement ce défaut, et c'est pourquoi c'est la méthode de référence depuis des décennies.

La régression logistique

Elle apprend **un poids par mot**, puis les combine pour trancher.

Son grand avantage : elle est **directement interprétable**. On peut ouvrir le modèle et lire mot par mot ce qu'il a retenu, ce qui est impossible avec un réseau de neurones. Pour une audience non technique, c'est un argument précieux.

Sa limite, connue d'avance

Cette approche traite le tweet comme un **sac de mots** : elle compte les mots présents mais ignore complètement leur ordre.

« not good » = « good not »

C'est précisément la faiblesse que les approches 2 et 3 viendront corriger.

Quatre configurations testées, un résultat contre-intuitif

CONFIGURATION	N-GRAMMES	MOTS VIDES	EXACTITUDE	AUC ROC	DURÉE
Référence, réponse au hasard			0,4989	0,4989	
Mots seuls	1	conservés	0,7980	0,8766	18 s
Mots seuls, sans mots vides	1	retirés	0,7894	0,8679	11 s
Avec paires de mots	1 et 2	conservés	0,8218	0,9006	54 s
Avec paires, sans mots vides	1 et 2	retirés	0,8076	0,8865	41 s


Le résultat qui surprend

Retirer les mots vides fait perdre 1,4 point quand on utilise les paires de mots. C'est l'inverse de ce qu'enseignent la plupart des tutoriels.

Rétrospectivement c'est logique : les paires **ont besoin** de ces mots pour exister.

Supprimer *not* avant de former « not good » détruit précisément l'information qu'on cherchait à capturer.

Les mêmes chiffres, vus dans MLflow



Run Name	Created	Dataset	Duration	Source	Models	auc_roc	exactitude	rappel_negatif
model_renu_03_avec...	1 month ago	-	13.6s	CIUsers...	analyse-sentiment-air-pars...	0.90061487...	0.82183101...	0.81431517...
04_avec_bigrammes_sans...	1 month ago	-	51.3s	CIUsers...	-	0.88654122...	0.80763680...	0.79839057...
03_avec_bigrammes	1 month ago	-	59.9s	CIUsers...	-	0.90061487...	0.82183101...	0.81431517...
02_mots_seuls_sans_mots...	1 month ago	-	17.1s	CIUsers...	-	0.86787872...	0.78937674...	0.77519546...
01_mots_seuls	1 month ago	-	21.7s	CIUsers...	-	0.87666208...	0.79797959...	0.78876401...
00_reference_hasard	1 month ago	-	24.3ms	CIUsers...	-	0.49888977...	0.49892587...	0.50261711...

Le tableau ci-dessus n'est pas recopié à la main : chaque ligne est un run enregistré, avec ses réglages, ses scores et sa durée. **La décision se prend sur la mesure**, et elle reste vérifiable des mois plus tard.

Les word embeddings : qu'est-ce que c'est ?

Le problème avec les numéros

Après découpage, le mot *terrible* devient le numéro 4271 et *awful* le numéro 5893. Ces numéros traduisent la fréquence, pas le sens. Rien ne dit au modèle que ces deux mots veulent dire à peu près la même chose.

Ce qu'apporte un embedding

Chaque mot est remplacé par une **liste de 200 nombres**, apprise de telle façon que deux mots employés dans des contextes similaires reçoivent des listes similaires.

Le modèle peut alors **généraliser** : s'il a beaucoup vu *awful*, il saura traiter *terrible* même s'il l'a peu rencontré.

Le principe qui rend ça possible

« *On connaît un mot à la compagnie qu'il fréquente.* »

John Firth, linguiste, 1957

Si *terrible* et *awful* apparaissent tous les deux souvent après « this was » et avant « experience », alors ils ont probablement un sens proche. Aucune connaissance du dictionnaire n'est nécessaire, seulement des statistiques d'usage.

Le réseau de neurones récurrent

Il lit le tweet **mot après mot, dans l'ordre**, en gardant une mémoire de ce qu'il a déjà lu. C'est ce qui lui permet de comprendre qu'un *not* placé au début modifie un *good* qui arrive trois mots plus loin.

Deux jeux d'embeddings comparés, comme demandé

Word2Vec, entraîné sur nos tweets

240 000 tweets, les nôtres. Les vecteurs collent exactement à notre domaine, le langage des tweets de 2009.

Inconvénient : c'est peu pour apprendre le sens de 20 000 mots.

GloVe Twitter, pré-entraîné

2 milliards de tweets, publié par l'université Stanford. Une connaissance de la langue incomparablement plus riche.

Inconvénient : il ne connaît pas les particularités de notre corpus.

Ce qu'ils considèrent comme les mots les plus proches de *delayed*

SOURCE	LES SIX MOTS LES PLUS PROCHES	PERTINENTS
Word2Vec 240 000 tweets	yesterdays, boarding, closing, postponed , council, rapid	1 / 6
GloVe 2 milliards de tweets	delay, postponed, delays, cancelled, canceled, scheduled	6 / 6

GloVe l'emporte de **1,26 point d'exactitude**, et l'on peut voir pourquoi plutôt que de se contenter du score. Détail savoureux : parmi les 183 mots de notre vocabulaire absents de GloVe, on trouve des noms d'applications Twitter de 2009 disparues depuis, *twitterberry*, *ubertwitter*, *twitterfon*. Notre corpus a quinze ans.

Choisir l'architecture sur une mesure, pas sur une habitude

La question

Deux types de réseaux récurrents s'imposent en pratique. Le **LSTM** possède trois portes qui décident à chaque mot ce qu'il faut garder en mémoire, oublier, et sortir. Le **GRU** fait la même chose avec deux portes : il est plus léger.

La littérature dit que les deux se valent souvent. Plutôt que de choisir par habitude, j'ai mesuré sur une époque, avec exactement les mêmes données.

Bidirectionnel, pourquoi ?

On lit le tweet deux fois, du début à la fin puis de la fin au début. Le sens d'un mot dépend autant de ce qui le suit que de ce qui le précède.

ARCHITECTURE	TEMPS PAR ÉPOQUE	SCORE DE VALIDATION
LSTM bidirectionnel 64	74,9 s	0,7982
GRU bidirectionnel 64	56,3 s	0,7989

La décision

Le GRU est **25 % plus rapide pour un score identique**. Aucune raison de prendre le LSTM.

La même méthode a servi pour la taille des lots : 512 s'est révélé à la fois plus rapide et plus performant que 256.

Ces mesures prennent quelques minutes et font gagner des heures sur l'ensemble du projet.

Quatre configurations, suivies dans MLflow

Runs

Views

+

metrics.rmse < 1 and params.model = "tree"

All time

State: Active

Datasets

+

New run

Sort: Created

Columns

Group by

	Run Name	Created	Duration	auc_roc	duree_entrainement	exactitude	rappel_negatif	
	modele_retenu_03_glove...	20 hours ago	13.6s	0.89366212...	-	0.81305	0.80153333...	
	04_glove_twitter_affine	20 hours ago	6.0min	0.89101427...	350.067239...	0.80928333...	0.8175	
	03_glove_twitter_figé	20 hours ago	8.3min	0.89366212...	494.092758...	0.81305	0.80153333...	
	02_word2vec_notre_corpus	20 hours ago	7.2min	0.88333406...	423.039279...	0.80053333...	0.78053333...	
	01_sans_embeddings_pre...	20 hours ago	4.1min	0.87979174...	240.294680...	0.79846666...	0.80693333...	

+

Show more columns (23 total)

Les quatre entraînements enregistrés dans MLflow, avec leurs scores et leur durée. Cliquez sur l'image pour l'agrandir.

Ce que chaque configuration teste

Sans embeddings pré-entraînés : que vaut le réseau sans aide extérieure ? C'est la référence.

Word2Vec figé : un corpus petit mais parfaitement adapté.

GloVe figé : un corpus 8 000 fois plus gros mais générique.

GloVe affiné : et si on laisse le réseau adapter GloVe ?

Deux enseignements

Les embeddings pré-entraînés apportent **+1,5 point** par rapport à un apprentissage depuis zéro.

Figé vaut mieux qu'affiner : 0,8131 contre 0,8093. Avec seulement 240 000 tweets, laisser bouger 4 millions de paramètres fait sur-apprendre. C'est à la fois moins cher et meilleur.

BERT : qu'est-ce que c'est, et qu'est-ce que ça change ?

La limite des embeddings classiques

Un mot a **un seul vecteur**, quel que soit son contexte. Dans « the room is light » et « this bag is light », le mot *light* a exactement la même représentation. Le modèle doit deviner lequel des deux sens s'applique.

Ce que fait BERT

Il produit un vecteur **différent pour chaque occurrence**, calculé en fonction de tous les autres mots de la phrase. C'est une représentation contextuelle.

Le mécanisme s'appelle **l'attention** : pour chaque mot, le modèle calcule à quel point chacun des autres lui est utile. Dans « the flight was not good », le mot *good* regarde directement *not*, sans avoir à faire circuler l'information de proche en proche.

Le transfert d'apprentissage

BERT a été pré-entraîné par Google sur des milliards de mots, à un jeu simple : on lui masque des mots au hasard et on lui demande de les deviner. Pour y arriver, il a bien fallu qu'il apprenne le fonctionnement de l'anglais.

On récupère ce modèle déjà entraîné et on l'adapte à notre tâche : **au lieu de partir de zéro, on part de quelqu'un qui sait déjà lire.**

Pourquoi DistilBERT et pas BERT ?

DistilBERT est une version allégée : **40 % plus petite, 60 % plus rapide**, et elle conserve environ 97 % des performances.

Sans carte graphique, c'était le seul choix raisonnable. Il compte tout de même **66 millions de paramètres**.

Le coût, mesuré avant d'écrire une ligne de code

Marc demandait « si nous devons investir dans ce type de modèle ». La réponse n'est donc pas seulement un score : **c'est un score rapporté à son coût**. J'ai mesuré le débit de DistilBERT sur ce processeur avant de concevoir le notebook.

STRATÉGIE	DÉBIT	10 000 TWEETS	50 000 TWEETS
BERT figé, calculs « aller » seulement, lots de 32	32,7 tweets/s	5 min	25 min
BERT figé, lots de 64	27,3 tweets/s	6 min	30 min
Affinage, « aller » et « retour », lots de 32	7,2 tweets/s	23 min par époque	115 min par époque
Affinage, lots de 16	6,6 tweets/s	25 min par époque	126 min par époque

L'affinage coûte 4,5 fois plus

Ce qui correspond à la théorie : la rétropropagation coûte environ deux fois l'aller, plus la mise à jour des poids.

Des lots plus gros n'aident pas

Contrairement au réseau récurrent, BERT sature déjà le processeur avec des lots de 32. C'est le calcul qui limite, pas la mémoire.

La décision

10 000 tweets et non 50 000. Affiner sur 50 000 aurait demandé près de 4 heures par passage. À garder en tête pour la comparaison.

BERT figé contre BERT affiné : le résultat le plus instructif

Stratégie A • BERT figé en extracteur

0,7690 **6 min**

exactitude

de calcul

Le plus mauvais score de tout le projet. Un modèle de 66 millions de paramètres se fait battre par une régression logistique.

Stratégie B • BERT affiné, 2 époques

0,7990 **44 min**

exactitude

de calcul

+3 points pour un coût de calcul **7 fois supérieur**. L'affinage n'est pas une option, c'est une nécessité.

Run Name	Created	Dataset	Duration	Source	Models	auc_roc	exactitude	rappel_négatif
modele_yetenu_bert	1 month ago	-	1.6min	CI/Users...	analyse-sentiment-air-paradis	0.87858900...	0.799	0.798
B_bert_affine	1 month ago	-	51.5min	CI/Users...	-	0.87858900...	0.799	0.798
A_bert_figé_extracteur	1 month ago	-	6.3min	CI/Users...	-	0.84307199...	0.769	0.757

Les trois runs de l'expérience BERT dans MLflow. Le rappel négatif, la mesure qui intéresse Air Paradis, chute lui aussi : 0,757 pour BERT figé contre 0,798 pour BERT affiné.

Pourquoi BERT figé est-il si mauvais ? Ce n'est pas une anomalie.

BERT a été pré-entraîné à **deviner des mots masqués**, pas à résumer des phrases. Le vecteur qu'on récupère pour représenter le tweet entier n'a jamais été entraîné à porter un sens global : il n'a été entraîné à rien du tout tant qu'on ne l'affine pas.

C'est un résultat documenté dans la littérature, et c'est ce qui a motivé la création de modèles spécialisés comme Sentence-BERT. **Sans affinage, BERT est un moteur puissant mais débrayé.**

PARTIE III

La comparaison

Les trois approches sont mesurées. Mais les comparer directement serait une erreur, et le résultat en serait faux.

Le piège de la comparaison naïve

Le classement brut

APPROCHE	EXACTITUDE	TWEETS VUS
Classique	82,2 %	1 214 000
Avancé	81,3 %	240 000
BERT	79,9 %	8 000

Le classement est **exactement inverse de la sophistication**. On pourrait en conclure que l'IA moderne ne sert à rien, et c'est d'ailleurs ce qu'on lit parfois.

Deux biais rendent ce tableau faux


- 1. La quantité de données.** Regardez la dernière colonne : il y a un **facteur 150** entre le premier et le dernier. Je ne comparais pas trois modèles, je comparais trois quantités de données.
- 2. Les jeux de test.** Chaque notebook avait tiré son propre échantillon, donc son propre jeu de test. Pire : un tweet du test de BERT pouvait très bien avoir servi à entraîner le modèle avancé.

Comment j'ai corrigé les deux

Un **jeu de test commun de 4 000 tweets** qu'aucun des trois modèles n'avait jamais vus à l'entraînement. C'est possible parce que la déduplication rend chaque texte unique et donc utilisable comme identifiant.

Puis la **courbe d'apprentissage** du modèle classique, sur laquelle je place les deux autres.

La comparaison à données égales



Comment lire ce graphique

La courbe bleue montre ce qu'obtient une régression logistique selon la quantité de données. C'est la référence. Les deux autres modèles sont placés au nombre de tweets qu'ils ont **réellement** **vus**.

Au-dessus de la courbe : le modèle fait mieux qu'une méthode simple disposant des mêmes données, sa complexité apporte quelque chose. En dessous : l'inverse.

MODÈLE	TWEETS	LUI	LE CLASSIQUE	ÉCART
BERT	8 000	78,7 %	75,1 %	+3,6 pt
Avancé	240 000	81,0 %	80,4 %	+0,6 pt

Les deux modèles avancés gagnent. Le classement initial était entièrement un artefact de la quantité de données.

Mais la seconde ligne m'a arrêté. Mesurée sur 4 000 tweets seulement, elle ne prouve rien, et c'est le sujet de la diapositive suivante.

Vérifier sa propre conclusion avant qu'on le fasse pour vous

Le défaut que j'ai trouvé dans mon travail

J'avais mis de côté **279 087 tweets** qu'aucun des trois modèles n'avait vus. Je n'en ai utilisé que **4 000**.

Sur 4 000 tweets, une exactitude n'est connue qu'à **plus ou moins 1,2 point** près. Mon écart de 0,6 point était donc **plus petit que ma propre marge d'erreur**. La bonne méthode, mais pas assez de données pour la faire parler.

La correction, en une minute de calcul

Nouvelle mesure sur **251 730 tweets**, avec le modèle réellement déployé. La marge tombe à **plus ou moins 0,15 point**.

J'en profite pour corriger un second point : le réseau garde 10 % de ses données pour sa validation, il a donc appris sur **216 000 tweets** et non 240 000.

COMPARAISON, SUR 251 730 TWEETS	MODÈLE AVANCÉ	LE CLASSIQUE AU MÊME VOLUME	ÉCART	TEST DE MCNEMAR
Première mesure, sur 4 000 tweets	81,00 %	80,43 %	+0,57 pt	non significatif
Au volume annoncé, 240 000 tweets	81,35 %	80,55 %	+0,80 pt	p de l'ordre de 10 ⁻³⁰
Au volume réellement appris, 216 000	81,35 %	80,34 %	+1,01 pt	p de l'ordre de 10 ⁻⁴⁶

Le test de McNemar, en une phrase

Les deux modèles jugent exactement les mêmes tweets. Plutôt que de comparer deux pourcentages, ce test ne regarde que les tweets sur lesquels ils sont **en désaccord**, et demande si ces désaccords penchent d'un côté plus souvent que ne le ferait le hasard. Sur 31 434 désaccords, 16 723 donnent raison au modèle avancé contre 14 711 au classique.

Ce que j'en retiens

En prenant un échantillon trop petit, je sous-estimais mon propre résultat. L'écart réel est de 0,80 point, pas 0,57.

Et la conclusion est maintenant démontrée, pas seulement observée. C'est la différence entre un chiffre et un résultat.

Ce que les scores ne disent pas : la négation

Un pourcentage global cache les cas particuliers. Or pour Air Paradis, un cas compte plus que les autres. Voici des paires de phrases identiques à un mot près. La valeur est la probabilité que le tweet soit positif : **plus elle est basse sur la ligne négative, mieux c'est.**

PHRASE	MODÈLE AVANCÉ	BERT	LECTURE
this flight was good	0,941	0,972	Les deux effondrent le score. Réussi.
this flight was not good	0,032	0,027	
the crew was helpful	0,949	0,974	BERT réussit, le modèle avancé échoue.
the crew was never helpful	0,624	0,052	
i would recommend it	0,952	0,969	Le modèle avancé réussit, BERT échoue.
i would not recommend it	0,209	0,776	

Ce qui justifie toute l'approche

Les deux modèles gèrent la négation. Le classique aussi, mais **pour une raison plus fragile** : il ne lit pas l'ordre des mots, et c'est uniquement parce que je lui ai donné les paires de mots qu'il reconnaît « not good » comme un motif.

Il échoue dès que la négation s'éloigne du mot qu'elle inverse, parce que la paire n'existe alors plus.

Ce qu'aucun score ne montre

Les deux modèles avancés n'ont pas les mêmes angles morts : **chacun réussit là où l'autre échoue**. Un écart d'un point d'exactitude ne dit rien de cela.

La démarche MLOps

MLOps est la contraction de *Machine Learning* et *Operations*. C'est l'ensemble des pratiques qui font qu'un modèle ne reste pas coincé dans un notebook, mais qu'il finit en production, surveillé, et qu'on puisse le remplacer sans tout casser.

Tracer

Chaque expérimentation enregistrée avec ses réglages et ses scores.


Tester

48 tests automatisés, exécutés avant chaque mise en ligne.

Surveiller

Des traces en production et une alerte quand le modèle dérive.

MLflow : suivre les expérimentations, centraliser les modèles



Name	Latest version	Aliased versions	Created by	Last modified	Tags
analyse-sentiment-air-paradis-ava...	Version 1			09/01/2026, 03:06:12 ...	—
analyse-sentiment-air-paradis-bert	Version 1			09/01/2026, 04:21:24 ...	—
analyse-sentiment-air-paradis-clas...	Version 1			09/01/2026, 11:56:54 ...	—

Le catalogue de modèles : les trois approches enregistrées et versionnées.

Le suivi des expérimentations

14 entraînements enregistrés avec leurs réglages, leurs scores et leur durée. Sans cela, au bout de quinze essais, plus personne ne sait quelle configuration avait donné le meilleur résultat ni avec quels paramètres.


Les graphiques, matrices de confusion et courbes ROC sont attachés à chaque expérimentation et restent consultables une fois le notebook fermé.

La centralisation des modèles


Le catalogue apporte trois choses qu'un simple fichier sauvegardé n'apporte pas : un **numéro de version**, une **signature** qui décrit ce que le modèle attend en entrée, et le **lien vers l'expérimentation** qui l'a produit.

Un point de méthode : chaque modèle enregistré a été **rechargé et retesté**. Un modèle qu'on n'a pas ressorti n'est pas un modèle enregistré.

Le versioning du code



Le dépôt : github.com/Dimitriwts/projet7-analyse-sentiments




L'historique des commits.

Un choix de méthode : des messages de commit qui expliquent, pas qui décrivent

Un message comme « correction bug » n'apprend rien à personne. Chaque commit de ce projet explique **pourquoi** le changement a été fait, avec les chiffres qui l'ont motivé. Exemple réel : « Retirer les mots vides dégrade le modèle de 1,4 point : les bigrammes ont besoin de ces mots pour former "not good" ».

Six mois plus tard, c'est cet historique qui permet de comprendre une décision sans avoir à la redécouvrir. C'est aussi ce qui rend le dépôt lisible par quelqu'un d'autre que moi.

Les tests unitaires automatisés



Les 48 tests exécutés automatiquement dans le pipeline, avant tout déploiement.

Quatre groupes de tests

1. La synchronisation du nettoyage entre entraînement et production. **2.** La présence et la cohérence des artefacts du modèle. **3.** Les réponses des routes de l'API. **4.** Le refus propre des entrées invalides.


Le test le plus important du projet

```
test_le_nettoyage_est_identique_entre_src_et_api
```

Le tweet doit être nettoyé **exactement de la même façon** à l'entraînement et en production. Si les deux versions divergent, le modèle reçoit en ligne un texte qui ne ressemble pas à ce qu'il a appris, et ses réponses se dégradent **sans qu'aucune erreur ne s'affiche nulle part**.

Ce piège porte un nom, le *training/serving skew*. Ce test le rend impossible : si les deux fichiers diffèrent d'un seul octet, le déploiement échoue.

Le pipeline de déploiement continu



Chaque envoi de code déclenche les tests, puis le déploiement s'ils passent tous.

1

Les tests d'abord

Ils s'exécutent avec les dépendances de l'API et non celles de la modélisation : ils doivent tourner dans **le même environnement que la production**, sinon ils ne prouvent rien.

2

Le déploiement ensuite

Le job de déploiement **dépend** du job de tests. Si un seul test échoue, il est annulé et la version en ligne reste celle qui marchait. Personne ne peut mettre en ligne une version cassée.

3

La vérification enfin

Le pipeline interroge la route de santé de l'API après déploiement. Un déploiement peut réussir sans que l'application démarre : mieux vaut échouer franchement que laisser croire que tout va bien.

PARTIE V

La mise en production

Un modèle qui fonctionne dans un notebook ne vaut rien tant qu'il n'est pas en ligne. C'est là que j'ai passé autant de temps qu'à le construire, et c'est là que se trouvaient les vraies difficultés.

Ce qui casse entre le notebook et la production

1

Le modèle ne rentre pas

Le serveur gratuit est limité à **1 Go de mémoire**, quand TensorFlow en pèse 600 à la seule installation.

Solution : conversion au format TensorFlow Lite. De plusieurs centaines de mégaoctets à **4,2 Mo**, sans perdre un point de performance. La conversion a d'ailleurs échoué au premier essai, il a fallu reconstruire le réseau avec deux options particulières.

2

Une sauvegarde qui ne finit jamais

L'enregistrement d'un modèle est resté bloqué **46 minutes** sans message d'erreur.

Diagnostic avec un outil de vidage de pile : la bibliothèque avait changé son format de sauvegarde par défaut pour un format plus sûr, mais qui parcourt l'objet élément par élément. Avec 300 000 termes de vocabulaire, cela ne se terminait jamais.

3

Un entraînement 15 fois plus lent

Un cycle est passé de **65 à 941 secondes** sans qu'une ligne de code ait changé.

La cause n'était pas le modèle mais la mémoire : la machine saturée écrivait sur le disque. Un chargement de données trop gourmand a été corrigé, ramenant l'occupation de 1 068 Mo à 45 Mo.

Leur point commun, et pourquoi c'est le coeur du sujet

Aucun de ces trois incidents ne provoque d'erreur visible. Le système continue de fonctionner, simplement mal. Un modèle qui met quinze fois plus de temps, une sauvegarde qui traîne, une conversion qu'on croit réussie : rien ne s'affiche en rouge.

C'est exactement ce que la démarche MLOps cherche à rendre détectable, et c'est pourquoi chaque transformation du modèle a été suivie d'une vérification chiffrée.

L'API de prédiction, déployée sur Azure

API de prediction de sentiment, Air Paradis 1.0.0 OAS 3.1

[/openapi.json](#)

Predit si un tweet exprime un sentiment negatif ou positif. Modele sur mesure avance : embeddings GloVe Twitter et reseau de neurones recurrent bidirectionnel, converti au format TensorFlow Lite.

Informations

GET

/

Accueil

⌵

GET

/sante

Sante

⌵

Prediction

POST

/prediction

Prediction

⌵

Schemas

DemandeDePrediction >

Expand all

object

HTTPValidationError >

Expand all

object

ReponseDePrediction >

Expand all

object

ValidationError >

Expand all

object

La documentation interactive, générée automatiquement par FastAPI.

4,2 Mo 0,16 ms

le modèle déployé

par prédiction

Trois routes seulement

/ décrit l'API et le modèle réellement déployé. **/sante** est interrogée par Azure pour vérifier que l'application vit. **/prediction** reçoit un texte brut et renvoie un sentiment.

Cinq dépendances contre vingt-deux

Ni TensorFlow, ni pandas, ni scikit-learn. C'est une contrainte matérielle, pas une coquetterie. Moins il y a de code en production, moins il y a de choses qui peuvent casser.

La vérification qui compte

Les prédictions en ligne sont **identiques au chiffre près** à celles mesurées en local. « the flight was not good » donne 0,0365 sur ma machine comme sur le serveur.

Le suivi de la performance en production

Air Paradis, analyse du sentiment d'un tweet

Interface de test de l'API déployée sur Azure. Elle interroge la vraie API par le réseau, pas une copie locale.

Le tweet à analyser

@AirParadis my flight was delayed AGAIN, worst service ever

Analyser

Sentiment NEGATIF

Probabilité d'être positif
0.6%

Seuil de décision: 50%. En dessous, le tweet est classé négatif.

Ce que l'API a réellement analysé

Tweet nettoyé

my flight was delayed again worst service ever

Les liens, les mentions et la ponctuation sont retirés avant l'analyse, exactement comme pendant l'entraînement du modèle.

Cette prédiction vous paraît-elle juste ?

Oui, la prédiction est correcte

Non, la prédiction est fautive

L'interface interroge l'API déployée et demande à l'utilisateur de valider.

Pourquoi demander l'avis de l'utilisateur

Un modèle se dégrade avec le temps. Le langage évolue, les sujets changent, et les tweets d'aujourd'hui ne ressemblent plus à ceux de 2009 sur lesquels il a appris. On appelle cela la **dérive**.

Son danger est qu'elle ne se voit pas : le modèle continue de répondre avec assurance, simplement il se trompe plus souvent. Demander à l'utilisateur de signaler les erreurs est le moyen le plus direct de la détecter.

Ce que contient chaque trace

Pas seulement « il y a eu une erreur », mais de quoi en faire quelque chose : le tweet, sa version nettoyée, le sentiment prédit, la probabilité, et **l'écart au seuil de décision**.

Ce dernier champ distingue un modèle qui se trompe **en hésitant**, ce qui est acceptable, d'un modèle qui se trompe **avec aplomb**, ce qui l'est beaucoup moins. Aucun score global ne montre cela.

Les traces et le déclenchement de l'alerte

[illegible]

Les traces structurées dans Application Insights, interrogeables en KQL.

La règle, testée pour de vrai

Trois prédictions contestées en cinq minutes déclenchent un courriel. Test réel : **trois traces envoyées à 11 h 08, alerte déclenchée à 11 h 09**, courriel reçu dans la foulée.

 Microsoft Azure

Warning severity

 Alert 'alerte-3-predictions-faussees-en-5-min' was fired

Why did this alert fire?

Query condition crossed the threshold of 2 and reached a value of 1

Metric name	Count
Metric value	3
Operator	Greater Than
Threshold	2
Description	Trois tweets signales comme mal predicts en cinq minutes

Affected resource hierarchy

Subscription
[08c3df1c-3fb1-446c-ac2d-39272d7752](#) >

Resource Group
[rg-ai-paradis](#) >

Application Insights
[air-paradis-sentiment-dimitriwts](#)

Le courriel reçu : valeur mesurée 3, seuil 2.

Un défaut découvert en conditions réelles

La première version envoyait **cinq courriels pour un seul incident**, parce que la règle réévaluait la même fenêtre chaque minute. Corrigé en rendant l'alerte persistante. C'est un problème connu, **la fatigue d'alerte** : un système qui crie trop finit par ne plus être écouté.

Améliorer le modèle dans le temps

Les traces collectées ne servent pas seulement à alerter. Elles sont la matière première d'un cycle d'amélioration continue, et toute l'infrastructure nécessaire est déjà en place.

1

À court terme

analyser

Sur quels types de tweets le modèle se trompe-t-il ?
Les messages courts, l'ironie, un vocabulaire apparu récemment ?

Un tableau de bord suivant le **taux de contestation semaine après semaine** rendrait la dérive visible avant qu'elle ne devienne un problème.

2

À moyen terme

réentraîner

Les tweets signalés forment un jeu de données de grande valeur : **ce sont exactement les cas difficiles**.
Les faire étiqueter par un humain puis les ajouter aux données d'entraînement corrige le modèle là où il échoue vraiment, plutôt que de le renforcer là où il réussit déjà.

3

À long terme

automatiser

Dès que suffisamment de nouveaux exemples sont collectés, un modèle candidat est entraîné, **comparé au modèle en place sur un jeu de test figé**, et déployé seulement s'il fait mieux.
Le suivi des expérimentations, le catalogue de modèles, les tests et le déploiement automatique existent déjà : il ne manque que l'ordonnanceur.

La mesure qui compte pour Air Paradis

Depuis le début je compare des exactitudes. Mais l'exactitude compte les deux erreurs de la même façon, alors que pour Air Paradis elles ne coûtent pas pareil. La mesure du besoin, c'est le **rappel sur la classe négative** : sur 100 tweets réellement négatifs, combien le modèle en attrape.

Les trois approches sur cette mesure

APPROCHE	EXACTITUDE	RAPPEL NÉGATIF
Classique, 1 214 000 tweets	0,8218	0,8143
Avancé, 240 000 tweets	0,8131	0,8015
BERT affiné, 8 000 tweets	0,7990	0,7980

Le classement ne change pas, mais l'écart se resserre : sur la mesure qui intéresse le client, les trois modèles se tiennent en 1,6 point.

Le seuil de décision est un réglage métier

Le modèle rend une probabilité. C'est nous qui choisissons à partir de quelle valeur on déclenche une alerte. Monter ce seuil élargit le filet. Mesuré sur les 251 730 tweets, avec le modèle déployé :

SEUIL	RAPPEL NÉGATIF	FAUSSES ALERTES	EXACTITUDE
0,50, la valeur par défaut	80,5 %	22 335	0,8135
0,55	83,1 %	25 635	0,8137
0,60	85,5 %	29 534	0,8102

Ma recommandation, chiffrée

Passer le seuil de 0,50 à 0,55. Sur ce jeu de 251 730 tweets, cela attrape **3 332 bad buzz de plus** sans rien perdre en exactitude, qui passe même de 0,8135 à 0,8137. La valeur par défaut n'était tout simplement pas la bonne pour ce besoin.

Si Air Paradis veut aller plus loin, 0,60 attrape 6 361 bad buzz de plus qu'au départ, pour 7 199 fausses alertes supplémentaires et un tiers de point d'exactitude. **C'est au client de trancher**, parce que le coût d'une fausse alerte est une minute de chargé de communication, et celui d'un bad buzz raté se compte autrement. Mon rôle est de lui donner le tableau, pas de choisir à sa place.

Quel modèle déployer ?

Le modèle sur mesure avancé, comme le demandait le cahier des charges, et les mesures le confirment. Il l'emporte à données égales, comprend les négations, et se sert en 0,16 milliseconde pour 4,2 Mo.

Faut-il investir dans BERT ?

Cela dépend de la quantité de données étiquetées. Avec 8 000 exemples, BERT écrase la régression logistique de 3,6 points. Avec 1,2 million déjà disponibles et sans carte graphique, le retour sur investissement est faible.

Investir dans BERT, ce n'est pas choisir un modèle, **c'est acheter l'infrastructure qui va avec.**

Ce que ce prototype ne fait pas encore

Il ne comprend que l'anglais. Pour le français, trois options : réentraîner sur un corpus français étiqueté, utiliser un modèle multilingue déjà entraîné, ou traduire avant de prédire. La première est la meilleure et la plus coûteuse, c'est la collecte des étiquettes qui pèse, pas le calcul.

Personne ne collecte les tweets. L'API traite un message par appel. Il manque en amont la collecte des mentions d'Air Paradis et, en aval, la personne qui reçoit l'alerte. Le modèle n'est pas le facteur limitant : à 0,16 milliseconde par tweet, une seule instance en absorbe plusieurs millions par jour.

Ce que ça coûte, en euros

POSTE	AUJOURD'HUI	EN SERVICE RÉEL
Hébergement de l'API	0 €, plan gratuit	quelques dizaines d'€ par mois
Suivi et alertes	environ 3 € par mois	idem
Entraînement du modèle	0 €, mon portable	0 €, moins d'une heure
Entraînement de BERT	non viable sans carte graphique	location à l'heure

Dépense réelle du projet : **0,25 €** sur les 200 \$ de crédits d'essai. Le modèle retenu est le seul des trois qui tient dans un plan gratuit, et c'est un argument de coût autant que de performance.

Ce que je retiens de ce projet

Mesurer plutôt que supposer. Trois de mes intuitions se sont révélées fausses : le retrait des mots vides, la cause d'un

Une comparaison doit être honnête. Le classement brut des trois approches donnait un résultat faux. Il a fallu construire un

La moitié du travail est après la modélisation. Faire sortir le modèle du notebook m'a pris autant de temps que de le

Merci

Des questions ?

Le dépôt, avec tout l'historique : github.com/Dimitriwts/projet7-analyse-sentiments

L'API a été déployée et vérifiée en production **jusqu'au 5 octobre 2026**, date d'expiration du crédit Azure gratuit.

La souscription est désactivée depuis, donc l'adresse ne répond plus. Les preuves sont dans le dépôt et dans ce support : documentation de l'API en ligne, pipeline au vert, traces et alerte.